# TECNOLÓGICO DE MONTERREY

MINERÍA DE DATOS

# Evaluación de universidades: análisis de componentes principales (PCA)

Reporte ejecutivo

Gabriel Omar Pérez Hernández

A01736195

9 de octubre de 2026

# Contenido

Resumen ejecutivo....2
1. Contexto: qué se quiere responder....2
2. Los datos y su preparación....2
3. Selección y tratamiento de las variables....3
4. ¿Los datos son aptos para un PCA?....4
5. Resultados del PCA....6
6. Cuántos componentes conservar....6
7. Qué significan los componentes....7
8. La estructura vista en gráficas....8
9. Aplicaciones prácticas y pensamiento crítico....9
10. Limitaciones del análisis....10
11. Conclusión....11

Clic derecho sobre el índice → «Actualizar campos» para refrescar los números de página.

## Resumen ejecutivo

- **Qué se hizo.** Se aplicó un PCA sobre las cuatro variables con las que 6,000 aspirantes de preparatoria califican a las universidades (prestigio, nivel académico, oferta académica y profesores), con datos estandarizados, pruebas de aptitud (Bartlett y KMO) y un análisis de estabilidad de 1,000 réplicas.
- **Qué se encontró.** Las cuatro variables prácticamente no se correlacionan (ninguna correlación supera $|r| = 0.03$; la mayor es +0.02). Bartlett no es significativo ($p = 0.245$), el KMO es de 0.50 y los eigenvalores son 1.04, 1.01, 0.98 y 0.97: ninguno supera el percentil 95 de datos aleatorios.
- **Decisión clave.** Aunque el criterio de Kaiser sugiere conservar 2 componentes, la evidencia completa indica que ninguna reducción está justificada: los cuatro criterios son dimensiones independientes y no existe un "factor general de calidad" que los resuma.
- **Qué se recomienda.** No resumir los criterios en un índice único: medir y atender cada atributo por separado, y validar con una encuesta de motivación por qué los aspirantes castigan un atributo específico.

## 1. Contexto: qué se quiere responder

Una institución que atrae aspirantes de preparatoria quiere saber si las cuatro cosas que estos evalúan —prestigio, nivel académico, oferta de carreras y profesores— pueden resumirse en menos dimensiones. Si el análisis de componentes principales muestra que dos o tres componentes capturan casi toda la información, la comunicación y el seguimiento pueden simplificarse, por ejemplo con un índice único de atractivo. Si no, cada atributo debe atenderse por separado, con mensajes y mejoras específicas para cada uno.

Esta tarea ejecuta ese análisis sobre la base oficial de la actividad. El objetivo no es solo correr el algoritmo, sino tomar una decisión fundamentada: cuántas dimensiones reales hay detrás de las cuatro calificaciones y qué se hace con esa respuesta.

## 2. Los datos y su preparación

La base Tarea 2_Base alumnos prepa.csv contiene 6,000 entrevistas con 10 columnas. La revisión de calidad encontró la base en buen estado: no hay valores faltantes (0), no hay filas duplicadas (0) y los identificadores son únicos. Dos detalles menores se atendieron al cargar, sin consecuencias para el análisis: el identificador venía duplicado como columna (ambas copias idénticas; se conservó una) y los nombres de las columnas traían la codificación de caracteres dañada en los acentos, que se corrigió al leer el archivo. Las cuatro variables de evaluación están en escala de 1 a 10 y ninguna registra valores fuera de rango. No se eliminó ninguna fila: el análisis trabaja con la base completa de 6,000 casos.

El contexto de cada respuesta: todas las filas corresponden a la primera universidad mencionada por el entrevistado; las respuestas provienen de 35 ciudades en 6 regiones del país. La universidad evaluada se concentra en la categoría OTRAS (4,946 casos, 82.4%), seguida por ITESM (502, 8.4%), UVM (453, 7.6%) y Anáhuac (99, 1.7%).

Los aspirantes tienden a calificar alto (Tabla 1 y Figura 1): las medias están entre 7.3 y 8.3 y las modas (de 7.8 a 8.4 según la variable) concentran entre 28% y 55% de las respuestas. La señal analítica de esta base no está en el nivel general de las calificaciones, sino en dónde aparecen las notas bajas.

| Variable | Media | Desv. | Mín. | Mediana | Máx. | Moda (%) |
|---|---|---|---|---|---|---|
| Prestigio | 8.25 | 1.60 | 1 | 8.4 | 10 | 8.4 (28%) |
| Nivel académico | 7.74 | 1.94 | 1 | 8.0 | 10 | 8 (44%) |
| Oferta académica | 7.29 | 2.23 | 1 | 7.8 | 10 | 7.8 (44%) |
| Profesores | 7.78 | 1.78 | 1 | 8.0 | 10 | 8 (55%) |

Tabla 1. Descriptivos de las cuatro variables de evaluación (n = 6,000).

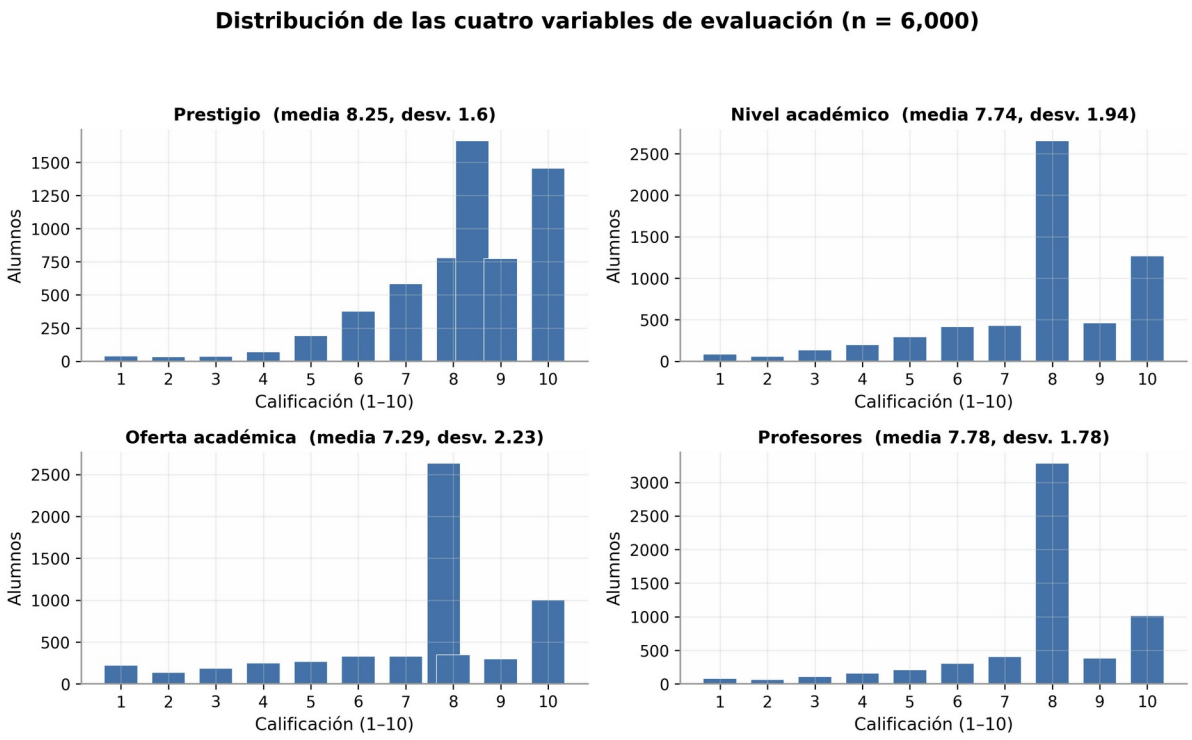



Figura 1. Distribución de las cuatro variables de evaluación. Las calificaciones se acumulan en valores altos; los valores bajos son poco frecuentes pero son los que diferencian a los aspirantes.

## 3. Selección y tratamiento de las variables

Al análisis entran las cuatro variables numéricas de evaluación. La justificación es doble:

- **Conceptual.** Cada variable mide un constructo distinto del valor que un aspirante percibe en una universidad: el prestigio captura la reputación, el nivel académico el rigor de los programas, la oferta académica la variedad de carreras y los profesores la calidad de la enseñanza. Son los cuatro criterios que la propia encuesta levantó como dimensiones de decisión.
- **Empírica.** Son las únicas cuatro columnas cuantitativas de la base; no hay más candidatas numéricas que evaluar.

Quedan fuera el identificador (ID_TEXT, solo numera filas) y las variables categóricas de contexto (ciudad, región, tipo de mención y universidad evaluada). El PCA requiere variables cuantitativas; las categóricas se usan para describir la muestra, como en la sección 2, pero no entran a la descomposición.

Sobre la estandarización: se aplicó. Las cuatro variables usan la misma escala (1–10), pero sus dispersiones difieren (desviaciones de 1.60 a 2.23; Tabla 1), y sin estandarizar el PCA ponderaría más a las variables más dispersas. Con z-scores los cuatro criterios aportan en igualdad de condiciones; en la práctica, el análisis se hace sobre la matriz de correlaciones. La verificación de la ejecución confirma que los scores resultantes tienen media ≈ 0 y desviación ≈ 1, como debe ser.

## 4. ¿Los datos son aptos para un PCA?

El PCA solo tiene sentido si las variables se mueven juntas: si una sube cuando otra sube (o baja), hay estructura común que comprimir. La evidencia de esta base dice lo contrario (Tabla 2, Figuras 2 y 3): las seis correlaciones entre pares están entre −0.00 y +0.02 —la mayor es +0.02 y ninguna supera |r| = 0.03—, es decir, en la práctica, cero.

| | Prestigio | Nivel académico | Oferta académica | Profesores |
|---|---|---|---|---|
| Prestigio | 1.00 | −0.00 | +0.02 | +0.00 |
| Nivel académico | −0.00 | 1.00 | +0.02 | +0.02 |
| Oferta académica | +0.02 | +0.02 | 1.00 | +0.01 |
| Profesores | +0.00 | +0.02 | +0.01 | 1.00 |

Tabla 2. Matriz de correlación de Pearson entre las cuatro variables. Ningún par supera |r| = 0.03.

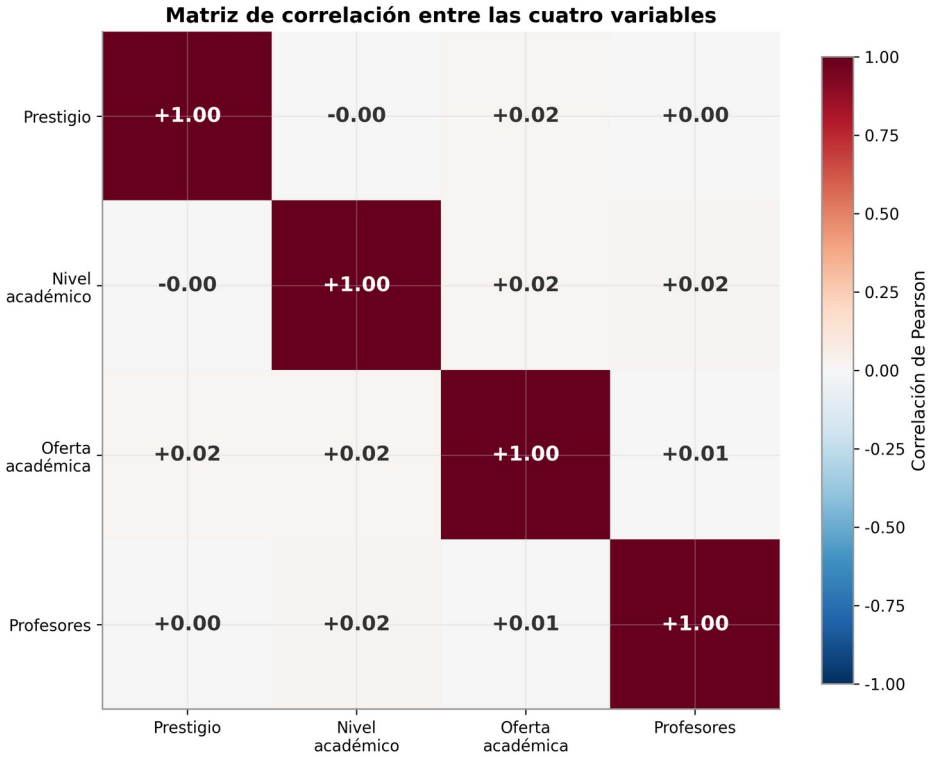



Figura 2. Matriz de correlación. Si las variables compartieran un factor común, las casillas fuera de la diagonal mostrarían tonos intensos de rojo o azul; todas están en blanco (valores cercanos a cero).

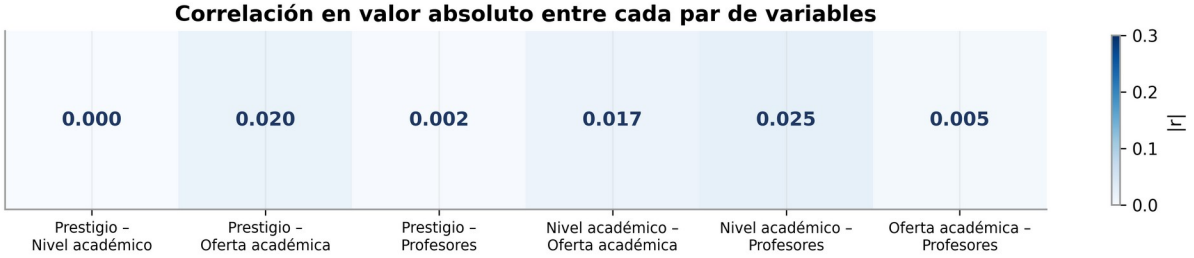



Figura 3. Correlación en valor absoluto de los seis pares de variables: ninguna supera 0.03.

Las pruebas formales de aptitud confirman la lectura (Tabla 3): la esfericidad de Bartlett no es significativa ($\chi^2 = 7.90$, gl = 6, p = 0.245), lo que significa que no se puede rechazar que la matriz de correlaciones sea una matriz de ceros; y el KMO es de 0.50, en el límite inferior de la zona “mediocre” y por debajo del umbral de 0.60 que suele exigirse para considerar un PCA apropiado.

| Prueba | Estadístico | Valor | Lectura |
|---|---|---|---|
| Bartlett (esfericidad) | $\chi^2$ (gl = 6) | 7.90 (p = 0.245) | No significativa: las correlaciones son indistinguibles de cero |
| KMO (adecuación) | Índice | 0.50 | Límite “mediocre”; por debajo del 0.60 usual |
| Correlación máxima | \|r\| | 0.025 | Sin pares de variables que se muevan juntos |

Tabla 3. Pruebas de aptitud de los datos para el PCA.

Lectura ejecutiva: no hay señal de que los cuatro criterios compartan un factor común. El análisis continúa —el ejercicio lo requiere y la evidencia completa tiene valor por sí misma—, pero con la alerta encendida y sin esperar una reducción limpia.

## 5. Resultados del PCA

El PCA estandarizado se ejecutó sobre las 6,000 observaciones. La verificación de la ejecución arroja lo esperado: los scores de cada componente tienen media 0 y desviación estándar ≈ 1 (entre 0.98 y 1.02), y la varianza explicada suma 100%. Los resultados (Tabla 4): los eigenvalores son 1.036, 1.012, 0.983 y 0.969; cada componente explica entre 24.2% y 25.9% de la varianza, una distribución casi perfectamente pareja; y con dos componentes solo se acumula 51.2% de la información.

| Comp. | Eigenvalor | % varianza | % acumulada | Kaiser (≥ 1) | Análisis paralelo (media) | Análisis paralelo (p95) |
|---|---|---|---|---|---|---|
| PC1 | 1.036 | 25.9% | 25.9% | Cumple | 1.028 | 1.045 |
| PC2 | 1.012 | 25.3% | 51.2% | Cumple | 1.009 | 1.019 |
| PC3 | 0.983 | 24.6% | 75.8% | No | 0.992 | 1.001 |
| PC4 | 0.969 | 24.2% | 100.0% | No | 0.972 | 0.985 |

Tabla 4. Eigenvalores, varianza explicada y comparación con el análisis paralelo (1,000 matrices aleatorias de 6,000 × 4).

Sobre la estabilidad —la evaluación que decide si los eigenvalores observados son estructura o ruido—: el análisis paralelo generó 1,000 matrices aleatorias del mismo tamaño y calculó sus eigenvalores. Con el estándar estricto (percentil 95), los dos eigenvalores observados (1.036 y 1.012) quedan por debajo del azar (1.045 y 1.019, Tabla 4): ni siquiera el primer componente se separa de lo que producirían datos sin estructura. Con la regla más laxa del promedio, PC1 y PC2 quedarían apenas retenidos (1.036 contra 1.028; 1.012 contra 1.009), un margen tan mínimo que no sostiene una reducción. En cualquiera de los dos estándares, no hay componentes sólidamente retenibles.

## 6. Cuántos componentes conservar

Los criterios para decidir cuántos componentes conservar se consultaron todos y no coinciden (Tabla 5). El criterio de Kaiser (eigenvalor ≥ 1) retendría 2 componentes; el scree plot no muestra un codo que justifique un corte; la varianza acumulada alcanza apenas 51.2% con dos componentes y solo pasa de 75% con tres; la interpretabilidad de PC1 es débil (carga pareja en todo, sección 7); y el análisis paralelo, la prueba de estabilidad, retiene cero componentes con el estándar estricto.

| Criterio | Indica | Evidencia en esta base |
|---|---|---|
| Kaiser (eigenvalor ≥ 1) | 2 componentes | 1.036 y 1.012 apenas superan 1; margen mínimo |
| Scree plot | Sin punto de inflexión | Curva plana: 1.04, 1.01, 0.98, 0.97 (Figura 4) |
| Varianza acumulada | 2 componentes ⇔ 51.2% | Umbral usual 70–80% no alcanzable sino con 3 o 4 |
| Interpretabilidad | Débil | PC1 carga parejo en las cuatro variables (0.32 a 0.61) |
| Análisis paralelo | 0 componentes | Ningún eigenvalor supera el percentil 95 del azar |
| Decisión de este informe | No reducir | Trabajar con las 4 variables originales |

Tabla 5. Contraste de criterios para el número de componentes.

La ambigüedad se reconoce de frente: si el ejercicio exigiera un número mecánico, la respuesta sería 2 por Kaiser. Pero esa decisión se sostiene solo en un criterio que aquí falla su propia prueba de estabilidad, y condensaría cuatro dimensiones independientes en dos que juntas pierden casi la mitad de la información. La decisión defendible es no reducir.

## 7. Qué significan los componentes

Con eigenvalores ≈ 1, la matriz de correlaciones es casi una matriz identidad y los ejes del PCA quedan mal anclados: pequeñas fluctuaciones de la muestra pueden rotarlos libremente. Las cargas (Tabla 6) se reportan como son, y las lecturas que siguen se presentan como hipótesis, no como hechos.

| Variable | PC1 | PC2 | PC3 | PC4 | Comunalidad (2 PC) |
|---|---|---|---|---|---|
| Prestigio | +0.32 | +0.69 | +0.55 | +0.35 | 0.58 |
| Nivel académico | +0.61 | -0.36 | -0.31 | +0.63 | 0.50 |
| Oferta académica | +0.54 | +0.44 | -0.51 | -0.50 | 0.49 |
| Profesores | +0.51 | -0.47 | +0.57 | -0.44 | 0.48 |

Tabla 6. Cargas de las variables y comunalidades con dos componentes.

- **PC1 — “apreciación general” (hipótesis).** Carga positiva en las cuatro variables (0.32 a 0.61), algo más alto en nivel académico (0.61). Se parece a un eje de valoración general: quien califica alto en un criterio tiende a calificar alto en todos. Pero con correlaciones ≈ 0 este patrón es también lo que produciría cualquier eje al azar, así que la lectura queda como hipótesis a validar, no como conclusión.
- **PC2 — “institucional vs. académico” (hipótesis).** Contrasta prestigio (+0.69) y oferta académica (+0.44) contra nivel académico (−0.36) y profesores (−0.47). Podría leerse como un eje que opone los atributos de marca y catálogo a los de rigor y docencia. Que explique

apenas 25.3% de la varianza y que el análisis paralelo lo ubique dentro del ruido obliga a tratarlo como especulación.

- **Lo que sí es dato:** las comunalidades con dos componentes son de 0.48 a 0.58, es decir, cada variable perdería casi la mitad de su información si el análisis se quedara en dos dimensiones. Con tres componentes mejoran (0.60 a 0.88), lo que confirma que ninguna dimensión sustituye a las originales.

## 8. La estructura vista en gráficas

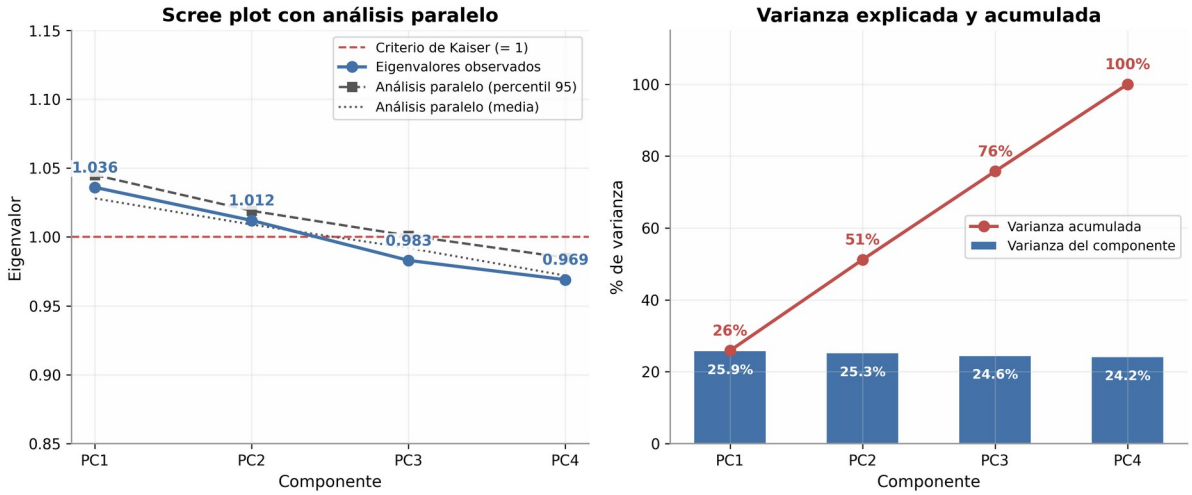



Figura 4. Scree plot con análisis paralelo (izquierda) y varianza explicada (derecha). Los eigenvalores observados (azul) quedan por debajo del percentil 95 de datos aleatorios (gris discontinuo): ni PC1 supera lo que el azar produce. La varianza se reparte casi por igual entre los cuatro componentes.

Qué muestra: que ningún componente se separa del ruido y que la curva de eigenvalores es plana. Qué no muestra: no prueba que los aspirantes no formen grupos —la segmentación es otra pregunta, respondida en la Tarea 1 con K-Means—; solo dice que las cuatro calificaciones no comparten eje lineal común.

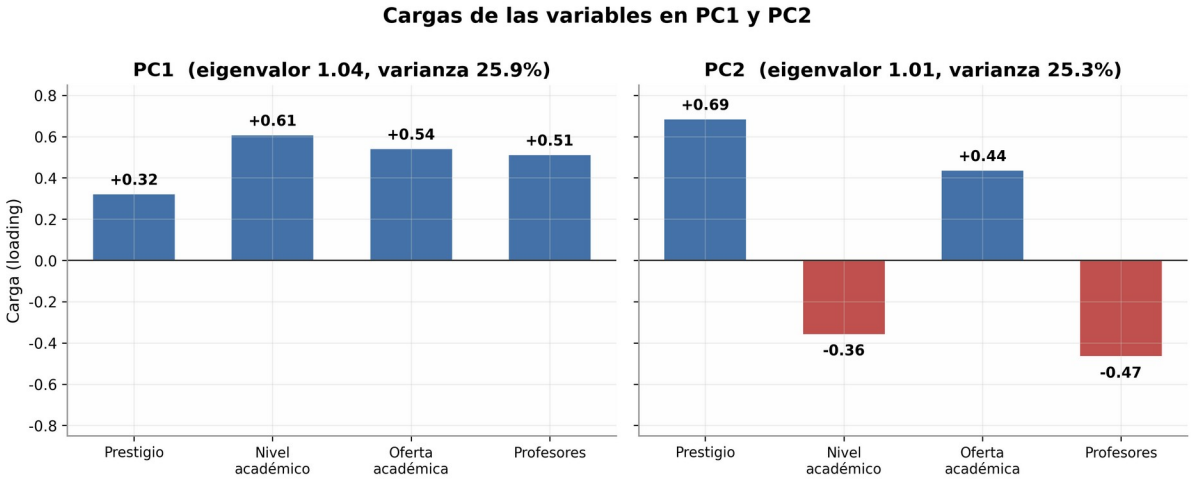


Figura 5. Cargas de las variables en PC1 y PC2. PC1 carga parejo en todo; PC2 contraste prestigio/oferta contra nivel/profesores. Con eigenvalores ≈ 1, estas direcciones son inestables y deben leerse como hipótesis.

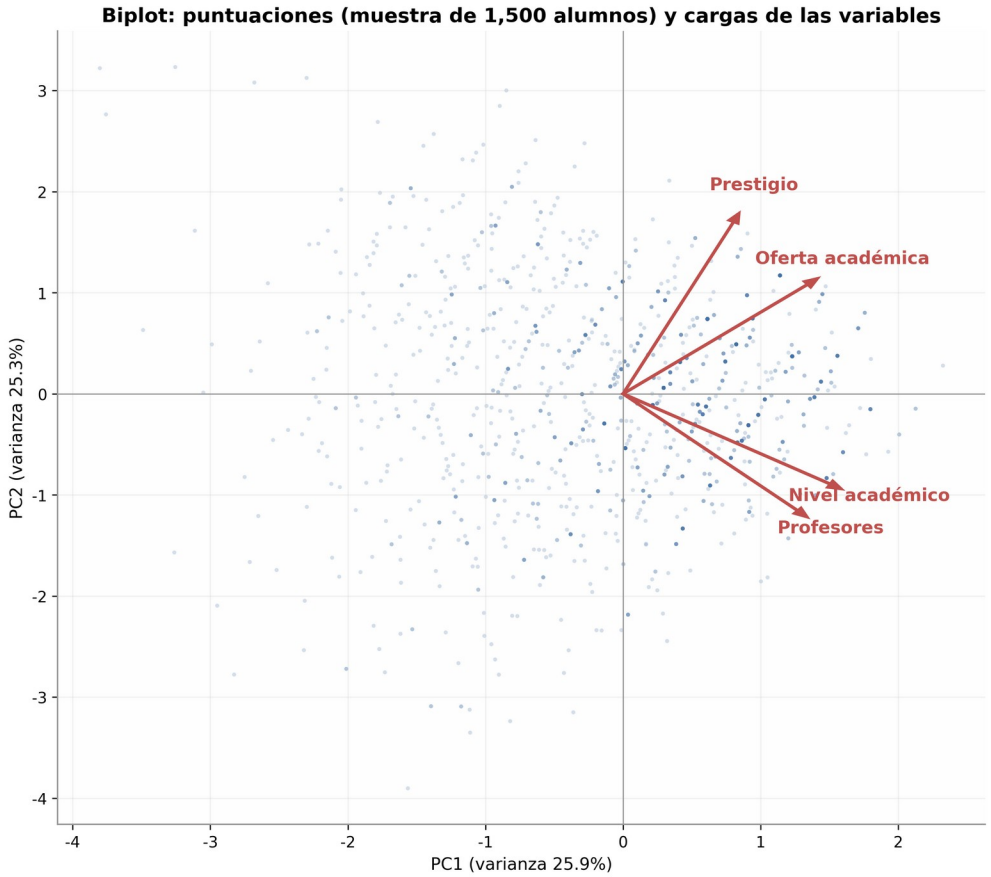



Figura 6. Biplot de las puntuaciones (muestra de 1,500 alumnos) y las cargas. La nube de puntos es redonda, sin ejes dominantes: ninguna dirección concentra más varianza que otra, la firma visual de ausencia de estructura factorial.

Estas gráficas no son ilustrativas: son la evidencia visual de las secciones 4 a 6. Juntas con las Tablas 3 y 4 sostienen la decisión de no reducir.

## 9. Aplicaciones prácticas y pensamiento crítico

Siguiendo la distinción metodológica entre lo que los datos muestran, lo que se infiere y lo que se propone hacer, esta sección se organiza en tres planos.

**Observaciones (lo que los datos muestran).**

- Las cuatro variables de evaluación no se correlacionan ($|r| \leq 0.03$); las pruebas de aptitud fallan ($p = 0.245$; KMO = 0.50) y ningún componente supera el azar en el análisis paralelo con el estándar estricto.
- Con dos componentes se preserva apenas 51.2% de la información; con las cuatro variables originales, 100%.

**Inferencias (hipótesis a validar, no conclusiones).**

- H1. Los aspirantes evalúan cada atributo de forma independiente: no hay efecto halo por el que una buena reputación arrastre las demás calificaciones.
- H2. La estructura de esta base es de segmentos, no de factores. Es coherente con la Tarea 1, donde el K-Means separó a los aspirantes por el atributo que cada uno castiga, no por un nivel general de exigencia.
- H3. Mejorar un atributo (por ejemplo, la oferta de carreras) no mejoraría automáticamente la percepción de los demás.

**Acciones propuestas (a probar, no a ejecutar a ciegas).**

- Medir y comunicar los cuatro atributos por separado; no construir un índice único de atractivo, porque resumiría mal la realidad.
- Diseñar mensajes específicos por atributo en lugar de un discurso genérico de "calidad".
- Antes de rediseñar la oferta, validar las hipótesis H1–H3 con una encuesta de motivación que pregunte por qué cada aspirante calificó bajo un atributo.
- Cruzar esta base con la segmentación de la Tarea 1 para decidir qué atributo atender en cada segmento.

La distinción importa y la rúbrica la pide explícitamente: reducción de dimensión ≠ segmentación ≠ causalidad. El PCA reduce dimensiones; no explica por qué los aspirantes califican como califican ni identifica grupos. Esa pregunta le corresponde a otros métodos (en este curso, al K-Means de la Tarea 1; la causalidad, a diseños experimentales).

## 10. Limitaciones del análisis

- La escala 1–10 es ordinal y se trató como intervalo, el supuesto estándar del PCA; con cuatro variables y correlaciones nulas, el resultado es robusto a esta elección, pero debe reconocerse.
- La base registra solo la primera universidad mencionada; no hay segunda mención ni comparación directa entre instituciones.
- Con solo cuatro variables, el tope de reducción es modesto incluso en el mejor escenario; un PCA sobre más atributos (por ejemplo, incluyendo becas y costo, como en la Tarea 1) podría comportarse distinto.
- La muestra es grande (n = 6,000), lo que hace que casi cualquier correlación mínima sea "significativa" en el sentido estadístico; la magnitud aquí (≤ 0.03) carece de importancia práctica, y es la magnitud la que guía la decisión.
- El análisis paralelo asume datos aleatorios gaussianos; con otra distribución de referencia los percentiles cambian marginalmente, sin alterar la conclusión.

## 11. Conclusión

El análisis de componentes principales se ejecutó de forma correcta y verificada sobre la base completa, y su respuesta honesta es que no hay estructura de correlación que comprimir: los cuatro criterios con los que los aspirantes evalúan a las universidades son dimensiones independientes. Ni el mejor criterio mecánico (Kaiser) sobrevive a su propia prueba de estabilidad.

La implicación práctica es clara: construir un índice único de atractivo destruiría casi la mitad de la información (con dos componentes se pierde 48.8%). La acción derivada no es estadística sino de gestión: medir y atender cada atributo por separado, y validar con datos de motivación por qué los aspirantes castigan el atributo que castigan. El resultado también cierra el ciclo con la Tarea 1: esta base separa a los aspirantes por prioridades independientes, no por factores latentes —el K-Means captó esa estructura, el PCA confirmó su naturaleza.